

تقرير فهم البيانات والتحليل الاستكشافي

تحليل ADHD وأنماط نشاط الدماغ بين الجنسين

تحليل شامل لبيانات تصوير الدماغ الوظيفي والمعلومات الديموغرافية والسلوكية للأطفال والمراهقين، بهدف بناء نموذج تنبؤي لتشخيص ADHD وتحديد الجنس.

EDA Report | ADHD & Sex Prediction | fMRI Connectome Analysis

فهرس المحتويات

١	نظرة عامة على البيانات	3
٢	توزيع المتغيرات الهدف	4
٣	تحليل القيم المفقودة	5
٤	توزيعات المتغيرات الرئيسية	6
٥	تحليل الارتباطات	7
٦	بيانات MRI الوظيفية	8
٧	الاستنتاجات والتوصيات	9

١. نظرة عامة على البيانات

المتغيرات الهدف

2

+ ADHD_Outcome
Sex_F

المتغيرات الوصفية

27~

كمية + فئوية

ميزات MRI

19,900

مصفوفة 200×200
Pearson

المشاركون (train)

1,213

مشارك كامل البيانات

ملفات البيانات

المتغير	الوصف	النوع	الملف
قيم مفقودة	ديموغرافيا، عرق، موقع المسح، تعليم الوالدين وعملهم	xlsx	TRAIN_CATEGORICAL_METADATA
قيم مفقودة	درجات EHQ، APQ، SDQ، ColorVision، عمر المسح	xlsx	TRAIN_QUANTITATIVE_METADATA
نظيفة	مصفوفة ارتباط Pearson لـ 200 منطقة دماغية	csv	TRAIN_FUNCTIONAL_CONNECTOME
نظيفة	المتغيران الهدف: ADHD_Outcome و Sex_F	xlsx	TRAINING_SOLUTIONS

وصف المتغيرات الفئوية

المتغير	الوصف
Basic_Demos_Enroll_Year	سنة التسجيل في الدراسة
Basic_Demos_Study_Site	موقع الدراسة (رمز)
PreInt_Demos_Fam_Child_Ethnicity	عرق الطفل
PreInt_Demos_Fam_Child_Race	جنس الطفل (تصنيف عرقي)
MRI_Track_Scan_Location	موقع جهاز MRI
Barratt_P1/P2 Edu/Occ	مستوى تعليم وعمل الوالدين

وصف المتغيرات الكمية

المجموعة	الوصف	عدد الأعمدة
EHQ_EHQ_Total	درجة اليد المفضلة (Handedness)	1
ColorVision_CV_Score	اختبار رؤية الألوان	1
*_APQ_P	استبيان الرعاية الوالدية Alabama (6 مقاييس فرعية)	6
*_SDQ_SQDQ	استبيان نقاط القوة والصعوبات (9 مقاييس فرعية)	9

1	عمر المشارك وقت المسح (~30% مفقود)	MRI_Track_Age_at_Scan
---	------------------------------------	-----------------------

٢. توزيع المتغيرات الهدف

⚠ **تحذير — عدم توازن البيانات:** البيانات غير متوازنة في كلا المتغيرين الهدف، وخاصة عند النظر إلى تقاطعهما. هذا يستلزم معالجة خاصة أثناء التدريب.



تقاطع ADHD × الجنس


ADHD (0) بدون	ADHD (1) مع	المجموع	نسبة ADHD
447	350	797	43.9%
294	122	416	29.3%
741	472	1,213	38.9%
		المجموع	
		ذكور (0)	
		إناث (1)	

ملاحظة مهمة: معدل ADHD عند الذكور (43.9%) أعلى بشكل ملحوظ من الإناث (29.3%)، وهذا يتوافق مع الأدبيات الطبية التي تشير إلى تشخيص ADHD بمعدلات أعلى عند الذكور. الفئة الأقل تمثيلاً هي **إناث مع ADHD** بـ 122 مشاركة فقط (~10% من الكل) — وهذا يجعل التنبؤ بهذه الفئة تحدياً خاصاً.

استراتيجيات معالجة الاختلال

- ١ **'class_weight='balanced** في XGBoost/LightGBM/sklearn — الأبسط والأكثر فاعلية.
- ٢ **Stratified K-Fold** عند التحقق من الصحة لضمان تمثيل متوازن في كل fold.
- ٣ **SMOTE** على مجموعة التدريب فقط لزيادة الفئة الأقل (إناث+ADHD).
- ٤ استخدم **F1-score** و**مقاييس AUC-ROC** بدلاً من Accuracy عند التقييم.

٣. تحليل القيم المفقودة



٤. توزيعات المتغيرات الرئيسية

درجات SDQ — مقارنة ADHD vs ADHD. بدون ADHD

SDQ (Strengths and Difficulties Questionnaire) هو أكثر المتغيرات فصلاً بين مجموعتي ADHD. التوزيعات في مجموعة ADHD منزاحة بوضوح نحو القيم الأعلى.

المقياس الفرعي	متوسط بدون ADHD	متوسط مع ADHD	الفرق	الدلالة
SDQ Hyperactivity	3.2~	6.8~	3.6+	عالٍ جداً
SDQ Externalizing	5.1~	9.8~	4.7+	عالٍ جداً
SDQ Difficulties Total	8.4~	14.2~	5.8+	عالٍ جداً
SDQ Generating Impact	0.8~	2.1~	1.3+	معتدل
SDQ Conduct Problems	1.4~	2.9~	1.5+	معتدل
SDQ Emotional Problems	2.3~	3.1~	0.8+	ضعيف

فروق بين الجنسين في المتغيرات

SDQ Emotional Problems: الإناث تسجل درجات أعلى في المشاكل العاطفية مقارنة بالذكور، حتى عند تساوي تشخيص ADHD.

SDQ Hyperactivity: توزيع الذكور يتركز عند القيم الأعلى. الإناث أكثر انتشاراً (flat distribution) — الذكور يُظهرون فرط نشاط أوضح.

SDQ Internalizing: الإناث تسجل قيمة أعلى قليلاً بشكل عام — ميل نحو الأعراض الداخلية بدلاً من الخارجية.

SDQ Externalizing: الذكور أعلى في السلوكيات الخارجية (نزاعات، عدوانية).

APQ_PP (Positive Parenting): فرق طفيف لصالح الإناث عند القيم المنخفضة — قد يكون مرتبطاً بالفروق في الأسلوب التربوي.

المتغيرات الفئوية — ملاحظات

Basic_Demos_Study_Site: بعض مواقع الدراسة تظهر نسب ADHD مختلفة — قد يعكس تحيزاً في الاختيار وليس فروقاً حقيقية.

Basic_Demos_Enroll_Year: التوزيع عبر السنوات متساوٍ نسبياً — لا تحيز زمني واضح.

MRI_Track_Scan_Location: الموقع مرتبط بمتغيرات MRI (~0.35 ارتباط Spearman) — يجب تضمينه ك covariate أو تطبيق تصحيح.

٥. تحليل الارتباطات (Spearman ρ)

تم اختبار ارتباط Spearman لأنه أكثر مرونة مع البيانات غير الطبيعية التوزيع والمتغيرات الترتيبية. التصنيف المستخدم: 0.3-0.0 ضعيف | 0.5-0.3 معتدل | 0.7-0.5 قوي | 0.7+ قوي جداً.

أقوى ارتباطات مع ADHD_Outcome

0.42 SDQ Generating Impact	0.48 SDQ Difficulties Total	0.52 SDQ Externalizing	0.55 SDQ Hyperactivity
--------------------------------------	---------------------------------------	----------------------------------	----------------------------------

ارتباطات مع Sex_F

✓ لا توجد ارتباطات قوية مع الجنس. لا يظهر أي متغير ارتباطاً خطياً واضحاً — التنبؤ بالجنس يتطلب نماذج غير خطية أو استكشاف تفاعلات مع بيانات MRI.

ارتباطات داخلية مهمة بين المتغيرات

المتغير الأول	المتغير الثاني	ρ	التفسير والتوصية
SDQ Conduct Problems	SDQ Externalizing	~0.90	تداخل مفاهيمي شديد — احذف أحدهما
SDQ Hyperactivity	SDQ Externalizing	~0.85	أعراض ADHD الأساسية متشابهة — استخدم PCA
SDQ Difficulties Total	SDQ Hyperactivity	~0.80	Total = مجموع الفرعية — تداخل بالتعريف
APQ_INV	APQ_PP	0.57	الوالد المنخرط أكثر إيجابية — طبيعي
APQ_PM	MRI Age at Scan	0.55	رقابة الوالد تتغير مع عمر الطفل
SDQ Prosocial	SDQ Conduct Problems	-0.52	علاقة عكسية طبيعية — السلوك الإيجابي ينعكس

ارتباطات MRI مع المتغيرات الوصفية

MRI_Track_Age_at_Scan ← Brain connectivity: ارتباط معتدل (~0.35) — العمر يؤثر على نمط الاتصال الدماغى. يجب الأخذ بعين الاعتبار عند النمذجة.

MRI_Track_Scan_Location ← Brain features: ارتباط معتدل (~0.30-0.40) — الموقع يؤثر على بيانات MRI. ضرورة تطبيق Site correction أو إدراجه كمتغير تحكم.

⚠ لا ارتباط مباشر بين ADHD و MRI: لم تظهر ارتباطات Spearman قوية بين ADHD والاتصالات الدماغية الفردية — الإشارة موزعة عبر شبكة من الاتصالات، وليس في اتصال واحد.

٦. بيانات MRI الوظيفية (Connectome)

القيم المفقودة صفر ✓ بيانات نظيفة	ارتباطات $0.3 <$ +110K تداخل عالٍ جداً	نطاق القيم [1, -1] معاملات Pearson	الميزات الكلية 19,900 نصف مصفوفة 200×200
--	---	---	--

كيف تُحسب مصفوفة Connectome؟

الخطوات: (١) تصوير fMRI في حالة الراحة → (٢) تصحيح الحركة وإزالة الضوضاء → (٣) تقسيم الدماغ إلى 200 منطقة اهتمام (ROI) → (٤) استخراج time series لكل منطقة → (٥) حساب ارتباط Pearson بين كل زوج من المناطق → مصفوفة 200×200 = 19,900 قيمة فريدة.

ما تعنيه القيمة؟ قيمة مرتفعة (+) = منطقتان تنشطان معاً (تزامن وظيفي). قيمة منخفضة (-) = منطقتان تعملان بشكل مستقل أو معاكس.

نتائج التحليل البصري للمصفوفات

النمط العام متشابه: المصفوفات الأربع (ADHD أنثى، ADHD ذكر، طبيعي أنثى، طبيعي ذكر) تبدو متشابهة بصرياً — الفروق الدقيقة لا تظهر للعين المجردة.

تحيز الارتباط الموجب: معظم الاتصالات إيجابية (أحمر في مصفوفة seismic) — يعكس التزامن الطبيعي في حالة الراحة.
بنية الكتل (Block structure): تظهر مناطق ارتباط عالٍ على القطر — تعكس الشبكات الدماغية الوظيفية المعروفة (Default Mode Network، الشبكة الحسية الحركية، إلخ).

إحصاءات القيم الخام

المجموعة	الحد الأدنى	الوسيط	الحد الأقصى
ADHD إناث	~0.72	~0.18+	~0.92+
ADHD ذكور	~0.70	~0.19+	~0.91+
طبيعي إناث	~0.73	~0.17+	~0.93+
طبيعي ذكور	~0.71	~0.18+	~0.92+

مشكلة الأبعاد العالية وحلولها

المشكلة	الوصف	الحل المقترح
Curse of dimensionality	19,900 ميزة مقابل 1,213 مشارك	PCA، Feature selection
Multicollinearity	+110K ارتباط $0.3 <$	PCA، Regularization
Overfitting	نسبة features/samples عالية	Cross-validation + Regularization
Computational cost	حسابات matrix كبيرة	تخفيض top-N components

توصيات MRI Feature Engineering

- ١ **PCA**: تقليل من 19,900 إلى 100-500 مكون رئيسي يحتفظ بـ 80-90% من التباين.
- ٢ **Graph features**: استخراج Node Strength, Clustering Coefficient, Path Length لكل من 200 منطقة.
- ٣ **Network-level features**: متوسط الاتصال داخل الشبكات الدماغية المعروفة (7 شبكات Yeo) كـ $7 \times 7 = 49$ ميزة.
- ٤ **Site correction**: تطبيق ComBat harmonization أو إدراج Scan Location كـ covariate.

٧. الاستنتاجات والتوصيات النهائية

الاستنتاجات الرئيسية

جودة البيانات

Connectome نظيف 100%.
المشكلة الرئيسية في Barratt
(~45% مفقود) وعمر MRI
(~30%).

بيانات MRI

إشارة ADHD موزعة على
الشبكة كاملة، ليست في
اتصال واحد — PCA ضروري.

فروق الجنس

لا ارتباط خطي واضح —
الفروق ظاهرة لكنها غير
خطية. تحتاج نماذج متقدمة.

تشخيص ADHD

درجات SDQ هي أقوى
المؤشرات الإحصائية (p حتى
0.55) — لكنها أعراض وليست
أسباباً.

المتغيرات الأكثر أهمية للنمذجة

SDQ Difficulties Total $p=0.48$ SDQ Externalizing $p=0.52$ SDQ Hyperactivity $p=0.55$

MRI Connectome (بعد PCA)

Demographics

APQ Parenting scores

SDQ Generating Impact $p=0.42$

Graph-level features

تحذيرات مهمة

⚠ **تداخل مفاهيمي في SDQ:** درجات SDQ هي في جوهرها أعراض ADHD نفسها — استخدامها كمميزات تنبؤية هو "circular reasoning". يُفضل استخدام PCA عليها أو فصل نماذج لكل مجموعة.

⚠ **عدم توازن البيانات:** فئة إناث+ADHD تمثل ~10% فقط. التجاهل سيؤدي لنموذج ضعيف عند الإناث تحديداً.

i بيانات Site تحتاج تصحيح: موقع المسح مرتبط بكل من بيانات MRI والديموغرافيا — يجب معالجته ك confound وليس feature.

خطة Feature Engineering الكاملة

١ **Categorical encoding:** One-hot encoding + فئة "Unknown" للمفقود + Target encoding للفئات ذات الكثافة المنخفضة.

٢ **SDQ composite:** PCA على 9 متغيرات SDQ → مكون أو مكونين رئيسيين بدلاً من 9 متغيرات متشابكة.

٣ **APQ normalization:** Scaling + إضافة متغير تفاعل APQ×Age إذا كان العمر متاحاً.

٤ **MRI dimensionality reduction:** PCA ($n=200$ أو نطاق واسع) + Graph statistics لكل منطقة + Network-average connectivity.

٥ **Imputation:** Median/KNN للمتغيرات الكمية. Barratt يُحذف كلياً.

توصيات النمذجة

النوع	النموذج المقترح	الملاحظة
Baseline	Logistic Regression + L2	نقطة انطلاق سريعة
Metadata فقط	XGBoost / LightGBM	class_weight + stratified CV

Dropout 0.3، 3 طبقات	PCA بعد MLP	MRI فقط
دمج تنبؤات المودلين	Late Fusion: Concat + XGB	Combined
أداء أعلى محتمل	GNN على بيانات graph	Advanced

مقاييس التقييم الموصى بها

المقياس الرئيسي: Balanced Accuracy أو Macro F1-score — مناسب للبيانات غير المتوازنة.
للمتابعة: AUC-ROC لكل فئة (ADHD ذكور، ADHD إناث) بشكل منفصل للتأكد من الأداء المتوازن.
تجنب: Accuracy البسيطة — ستعطي نتائج مضللة مع الاختلال.